

Research article

Komparasi Strategi Imputasi Missing Value pada Dataset Cuaca Australia untuk Prediksi Curah Hujan Menggunakan Random Forest Classifier

ARTICLE INFO

Keywords:

Missing Value, Imputasi Data, KNN Imputer, MICE, Random Forest, Prediksi Cuaca, *Data Mining*

G. R. Rabbani, R. Ikhsanti, C. Syawaldina, A. O. Rohila, A. S. Prasetyo, and M. Bimastiar, "Komparasi Strategi Imputasi Missing Value pada Dataset Cuaca Australia untuk Prediksi Curah Hujan Menggunakan Random Forest Classifier" *Jurnal Ilmiah Teknologi*, 2026.

ABSTRACT

Kehadiran missing value dalam proporsi signifikan merupakan tantangan utama dalam pemrosesan data cuaca berskala besar. Penelitian ini menyajikan komparasi sistematis terhadap lima strategi penanganan missing value penghapusan baris (Drop NA/Baseline), imputasi rata-rata (Mean), imputasi median (Median), K-Nearest Neighbor Imputer (KNN), dan Multivariate Imputation by Chained Equations (MICE) yang diterapkan pada dataset Rain in Australia dengan 145.460 observasi dan 22 fitur meteorologi. Variabel target yang digunakan adalah RainTomorrow (biner). Untuk mencegah kebocoran data, prosedur train-test split (80:20) dilakukan sebelum proses imputasi apa pun. Seluruh skenario menggunakan Random Forest Classifier (random_state=42) dengan metrik evaluasi F1-Score dan AUC-ROC. Hasil eksperimen menunjukkan bahwa metode Baseline (Drop NA) mencatat performa tertinggi (F1: 0,8530; AUC-ROC: 0,8979), diduga akibat mekanisme seleksi data implisit yang mempertahankan hanya observasi kondisi cuaca teratur. Di antara metode imputasi, Median Imputation menghasilkan F1-Score terbaik (0,8463) dengan waktu komputasi efisien dan cakupan prediksi penuh. Perbedaan performa antar metode imputasi bersifat marjinal ($\Delta F1 < 0,002$), mengindikasikan robustness Random Forest terhadap variasi kualitas imputasi. Penelitian ini merekomendasikan Median Imputation sebagai pilihan paling seimbang untuk prediksi curah hujan operasional yang membutuhkan ketangguhan dan cakupan penuh pada kondisi data tidak lengkap.

1. Pendahuluan

1.1 Latar Belakang

Dalam era komputasi modern, data cuaca menjadi salah satu sumber informasi yang paling intensif digunakan, mulai dari perencanaan pertanian, manajemen bencana, hingga sistem transportasi cerdas. Data tersebut umumnya diperoleh dari jaringan stasiun cuaca otomatis yang tersebar di berbagai wilayah geografis, sehingga secara inheren rentan terhadap gangguan teknis, kesalahan transmisi sensor, serta perbedaan jadwal pencatatan antar stasiun (Josse & Husson, 2016). Konsekuensinya adalah kemunculan missing values dalam jumlah yang tidak dapat diabaikan pada dataset Rain in Australia yang digunakan dalam penelitian ini, variabel seperti Evaporation dan Sunshine bahkan memiliki tingkat kehilangan data hingga 48%, sedangkan variabel Cloud9am dan Cloud3pm mencapai sekitar 40% missing (Young, 2016).

Kehadiran missing value tidak hanya menghambat proses komputasi algoritma machine learning, tetapi juga berpotensi mengintroduksi bias sistematis jika tidak ditangani secara tepat (García-Laencina et al., 2015). Pendekatan yang paling sederhana, yakni penghapusan seluruh baris yang mengandung nilai kosong (listwise deletion), dapat mengakibatkan hilangnya sebagian besar dataset, terutama ketika missing values tersebar di banyak kolom secara simultan. Di sisi lain, imputasi yang terlalu agresif menggunakan statistik sederhana seperti rata-rata atau median dapat memperhalus distribusi data dan menghilangkan pola varians yang sesungguhnya bermakna secara meteorologis.

Metode imputasi berbasis relasi multivariat, seperti K-Nearest Neighbor (KNN) dan Multivariate Imputation by Chained Equations (MICE), menawarkan pendekatan yang lebih canggih dengan memanfaatkan korelasi antar variabel untuk memperkirakan nilai yang hilang secara lebih akurat (van Buuren & Groothuis-Oudshoorn, 2011). Namun demikian, kedua metode ini memiliki kompleksitas komputasi yang lebih tinggi, sehingga evaluasi trade-off antara akurasi dan efisiensi menjadi pertimbangan yang relevan dalam konteks praktis.

Meskipun berbagai metode imputasi telah dikembangkan, belum terdapat konsensus yang jelas mengenai strategi terbaik khususnya untuk dataset cuaca dengan tingkat missing tinggi dan bervariasi antar variabel. Penelitian-penelitian sebelumnya yang menggunakan dataset Rain in Australia umumnya berfokus pada komparasi algoritma klasifikasi dengan asumsi data sudah bersih (Jerez et al., 2010; Afrifa-Yamoah et al., 2020), sehingga evaluasi sistematis terhadap strategi imputasi dalam pipeline yang bebas data leakage masih relatif terbatas. Penelitian ini hadir untuk mengisi gap tersebut dengan membandingkan lima strategi imputasi secara komprehensif pada dataset Rain in Australia, menggunakan Random Forest Classifier sebagai evaluator tunggal yang seragam.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, penelitian ini merumuskan tiga pertanyaan penelitian sebagai berikut:

1. Bagaimana karakteristik dan mekanisme missing value pada dataset Rain in Australia, dan apakah pola kehilangannya dapat dikategorikan sebagai MCAR, MAR, atau MNAR?

2. Bagaimana perbandingan performa model Random Forest Classifier yang dilatih pada data hasil kelima strategi penanganan missing value (Drop NA, Mean, Median, KNN, MICE) berdasarkan metrik F1-Score dan AUC-ROC?
3. Strategi imputasi manakah yang paling direkomendasikan untuk digunakan dalam membangun model prediksi curah hujan pada dataset meteorologi dengan tingkat kehilangan data yang tinggi?
4. Bagaimana pola missing value pada dataset Rain in Australia ditinjau dari dimensi spasial (per lokasi stasiun cuaca) dan temporal (per tahun), dan apa implikasinya terhadap pemilihan strategi imputasi yang tepat?

1.3 Tujuan Penelitian

Selaras dengan rumusan masalah yang telah diidentifikasi, penelitian ini bertujuan untuk:

1. Menganalisis pola dan mekanisme missing value pada dataset Rain in Australia menggunakan teknik visualisasi eksploratif.
2. Mengimplementasikan dan mengevaluasi lima strategi penanganan missing value dalam skenario yang terbebas dari data leakage, menggunakan Random Forest Classifier sebagai model evaluasi yang seragam.
3. Memberikan rekomendasi berbasis bukti empiris mengenai strategi imputasi yang paling efektif untuk data meteorologi.
4. Mengidentifikasi celah penelitian terkait dimensi spasial-temporal pola missing value dan keterbatasan generalisasi lintas algoritma klasifikasi sebagai dasar rekomendasi penelitian lanjutan.

1.4 Batasan Penelitian

Agar pembahasan tetap terfokus dan dapat direplikasi, penelitian ini memberlakukan beberapa batasan, antara lain:

1. Dataset yang digunakan adalah Rain in Australia versi publik dari Kaggle/UCI, dengan variabel target RainTomorrow (biner: Ya/Tidak).
2. Fitur kategorik dengan kardinalitas tinggi (seperti Location, WindGustDir) akan diproses menggunakan Label Encoding sederhana sebelum masuk ke tahap imputasi numerik.
3. Algoritma klasifikasi yang digunakan dibatasi hanya pada Random Forest Classifier dengan random_state=42 untuk memastikan reproduktibilitas hasil.
4. Evaluasi performa model difokuskan pada metrik F1-Score (weighted) dan AUC-ROC, mengingat adanya ketidakseimbangan kelas (class imbalance) yang cukup signifikan pada dataset ini.
5. Penelitian ini tidak melakukan pengujian statistik formal terhadap mekanisme missing value (seperti Little's MCAR Test atau PKLM Test) dan tidak mengimplementasikan imputasi berbasis lokasi geografis (grouped/spatial imputation). Kedua hal tersebut diidentifikasi sebagai celah penelitian dan direkomendasikan sebagai arah penelitian lanjutan.

6. Perbandingan performa strategi imputasi dibatasi hanya pada satu jenis classifier (Random Forest). Investigasi terhadap konsistensi ranking imputasi lintas algoritma lain seperti XGBoost atau Logistic Regression berada di luar lingkup penelitian ini dan menjadi bagian dari rekomendasi penelitian selanjutnya.
7. KNN Imputer diterapkan tanpa normalisasi fitur terlebih dahulu karena fokus penelitian ini adalah evaluasi strategi imputasi, bukan optimasi parameter. Konsekuensi dari keputusan ini, yaitu potensi dominasi fitur berskala besar seperti Pressure (>1000) terhadap jarak Euclidean, diakui sebagai keterbatasan dan didiskusikan di bagian analisis hasil.

2. Tinjauan Pustaka

2.1 Knowledge Discovery in Databases (KDD)

Knowledge Discovery in Databases (KDD) adalah proses non-trivial untuk mengidentifikasi pola-pola yang valid, baru, berpotensi berguna, dan pada akhirnya dapat dipahami dari data (Fayyad et al., 1996). Proses KDD terdiri dari beberapa tahapan yang saling berurutan, meliputi:

1. seleksi data,
2. preprocessing dan pembersihan data,
3. transformasi data,
4. penerapan algoritma data mining, dan
5. evaluasi serta interpretasi pola yang ditemukan.

Dalam konteks penelitian ini, tahap preprocessing khususnya penanganan missing value memegang peran yang sangat kritis karena kualitas data yang masuk ke tahap data mining secara langsung menentukan validitas pengetahuan yang dihasilkan. Prinsip "garbage in, garbage out" yang dikenal luas dalam komunitas ilmu komputer menegaskan bahwa bahkan algoritma pembelajaran mesin yang paling canggih pun tidak dapat mengkompensasi data masukan yang berkualitas buruk (Han et al., 2012).

2.2 Mekanisme Missing Value

Rubin (1976) mengklasifikasikan mekanisme missing data ke dalam tiga kategori yang kemudian menjadi landasan teoretis hampir seluruh literatur di bidang ini:

2.2.1 MCAR (Missing Completely at Random)

Kemungkinan suatu nilai hilang tidak bergantung pada nilai itu sendiri maupun pada variabel lain dalam dataset. Dalam konteks data cuaca, ini dapat terjadi akibat kegagalan sensor yang bersifat acak murni, misalnya akibat kerusakan baterai yang tidak terduga. Imputasi apa pun secara teoritis menghasilkan estimasi yang unbiased pada kondisi ini.

2.2.2 MAR (Missing at Random)

Kemungkinan suatu nilai hilang bergantung pada variabel lain yang terobservasi, bukan pada variabel itu sendiri. Sebagai contoh, data Sunshine (lama penyinaran matahari) mungkin lebih sering hilang di stasiun-stasiun yang berlokasi di daerah berawan secara struktural, di mana kondisi ini tercermin melalui variabel Cloud9am atau Cloud3pm yang terobservasi. MAR adalah asumsi yang paling sering digunakan dalam metode imputasi modern karena memungkinkan penggunaan informasi dari variabel terobservasi untuk memperkirakan nilai yang hilang.

2.2.3 MNAR (Missing Not at Random)

Kemungkinan suatu nilai hilang bergantung pada nilai variabel itu sendiri yang tidak terobservasi. Ini adalah skenario yang paling problematik; misalnya, sensor tekanan udara mungkin gagal mencatat nilai justru ketika terjadi penurunan tekanan yang ekstrem (saat badai). MNAR memerlukan pemodelan mekanisme kehilangan data

secara eksplisit, yang jauh lebih kompleks dan sering kali membutuhkan asumsi tambahan yang sulit diverifikasi (Rubin, 1976).

2.3 Strategi Penanganan Missing Value

2.3.1 Penghapusan Data (Listwise Deletion)

Pendekatan paling konservatif adalah menghapus seluruh baris yang mengandung setidaknya satu nilai kosong. Meskipun menghasilkan dataset yang "bersih" secara instan, metode ini berisiko membuang sejumlah besar informasi yang valid, terutama ketika missing values tersebar di banyak kolom (Allison, 2001). Pada dataset dengan banyak fitur seperti Rain in Australia, penghapusan ini dapat mengeliminasi hingga lebih dari separuh observasi.

2.3.2 Imputasi Mean dan Median

Imputasi statistik sederhana mengisi nilai yang hilang dengan rata-rata (mean) atau nilai tengah (median) dari distribusi kolom yang bersangkutan (Saunders et al., 2006). Kelebihan utamanya adalah simplisitas dan efisiensi komputasi. Namun, kedua metode ini memiliki kelemahan fundamental: mereka mengabaikan struktur korelasi antar variabel serta mereduksi variansi data secara artifisial, yang dapat menyebabkan underestimasi ketidakpastian model.

2.3.3 K-Nearest Neighbor Imputer

KNN Imputer mengisi nilai yang hilang dengan rata-rata tertimbang dari k tetangga terdekat dalam ruang fitur yang terobservasi (Troyanskaya et al., 2001). Kedekatannya diukur menggunakan jarak Euclidean atau jarak lain yang sesuai. Karena memanfaatkan informasi dari sampel-sampel yang secara karakteristik serupa, KNN mampu mempertahankan struktur multivariat data dengan lebih baik dibandingkan imputasi univariat. Scikit-learn mengimplementasikan ini melalui kelas KNN Imputer (Pedregosa et al., 2011).

KNN Imputer berbasis jarak Euclidean sehingga sensitif terhadap skala fitur, fitur berskala besar akan mendominasi perhitungan jarak (Troyanskaya et al., 2001; Géron, 2022). Dalam penelitian ini, normalisasi tidak dilakukan agar seluruh skenario berada pada kondisi preprocessing yang seragam, sehingga perbedaan performa yang terukur murni mencerminkan perbedaan strategi imputasi. Keterbatasan ini diakui dan dibahas pada Bab 4.

2.3.4 MICE (Multivariate Imputation by Chained Equations)

MICE, yang diimplementasikan sebagai `IterativeImputer` dalam Scikit-learn, adalah teknik imputasi yang bekerja melalui serangkaian regresi berantai (van Buuren & Groothuis-Oudshoorn, 2011). Pada setiap iterasi, setiap variabel yang memiliki missing value dimodelkan sebagai fungsi dari seluruh variabel lain, kemudian nilai yang hilang diimputasi dari model regresi tersebut. Proses ini diulang hingga konvergensi tercapai. MICE secara umum dianggap sebagai salah satu metode imputasi paling kuat dan fleksibel, karena secara implisit memodelkan dependensi multivariat yang kompleks.

2.4 Metrik Evaluasi

2.4.1 Accuracy, Precision, dan Recall

Accuracy mengukur proporsi prediksi yang benar dari keseluruhan sampel. Meskipun intuitif, metrik ini tidak representatif pada dataset yang tidak seimbang karena model dapat mencapai accuracy tinggi hanya dengan memprediksi kelas mayoritas secara konsisten. Precision mengukur proporsi prediksi positif yang benar-benar positif, sedangkan Recall (sensitivitas) mengukur proporsi sampel positif yang berhasil terdeteksi (Fawcett, 2006)

2.4.2 F1-Score

F1-Score adalah rata-rata harmonik antara precision dan recall, yang diformulasikan sebagai:

$$F_1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Metrik ini sangat relevan untuk masalah klasifikasi dengan ketidakseimbangan kelas, seperti prediksi hujan di mana kelas "No" jauh lebih dominan. F1-Score weighted mempertimbangkan proporsi masing-masing kelas, sehingga memberikan gambaran yang lebih representatif tentang performa model secara keseluruhan.

2.4.3 Area Under the ROC Curve (AUC-ROC)

AUC-ROC mengukur kemampuan diskriminatif model secara keseluruhan dengan merangkum kurva ROC (Receiver Operating Characteristic) menjadi satu nilai skalar antara 0 dan 1. Nilai AUC = 0.5 mengindikasikan model tanpa kemampuan diskriminasi (setara dengan tebakan acak), sedangkan AUC = 1.0 menandakan model yang sempurna. AUC-ROC tidak bergantung pada ambang batas klasifikasi, sehingga memberikan evaluasi yang lebih komprehensif terhadap kapabilitas model (Fawcett, 2006).

2.5 Penelitian terkait

Sejumlah penelitian sebelumnya telah menginvestigasi dampak strategi penanganan missing value terhadap performa model prediktif. García-Laencina et al. (2015) melakukan studi komparatif pada beberapa dataset medis dan menemukan bahwa metode imputasi berbasis neighborhood (termasuk KNN) secara konsisten mengungguli imputasi statistik sederhana, terutama ketika proporsi data yang hilang melebihi 20%. Temuan ini sejalan dengan dataset penelitian kami di mana beberapa fitur kunci memiliki missing rate di atas 40%.

Afrifa-Yamoah et al. (2020) mengevaluasi berbagai teknik imputasi pada data cuaca resolusi tinggi dari empat stasiun pantai Australia, termasuk variabel suhu, kelembapan, dan kecepatan angin, dan menemukan bahwa pendekatan regresi multivariat menghasilkan imputasi yang paling akurat, sementara metode univariat sederhana cenderung mengunderestimasi variansi data pada kondisi cuaca ekstrem. Temuan ini relevan langsung dengan konteks penelitian kami yang menggunakan data dari jaringan stasiun cuaca Australia dengan pola missing yang bervariasi antar wilayah.

Sementara itu, studi oleh Jerez et al. (2010) pada data klinis menunjukkan bahwa pilihan strategi imputasi dapat mengubah peringkat metode klasifikasi secara substansial,

menggarisbawahi pentingnya evaluasi imputasi sebagai bagian dari pipeline eksperimen yang komprehensif. Dalam konteks prediksi curah hujan secara spesifik, penelitian dengan dataset Rain in Australia umumnya berfokus pada komparasi algoritma klasifikasi seperti SVM, XGBoost, dan Deep Learning dengan asumsi data sudah bersih, sehingga penelitian yang secara eksplisit mengevaluasi dampak strategi imputasi terhadap performa prediksi curah hujan masih relatif terbatas.

2.6 Research Gap

Berdasarkan tinjauan pustaka yang telah dipaparkan pada subbab sebelumnya, terdapat empat celah penelitian yang belum dijawab secara memadai oleh literatur yang ada dan relevan terhadap konteks penelitian ini.

1. Tidak adanya pengujian statistik formal terhadap mekanisme missing value

Penelitian-penelitian sebelumnya yang menggunakan dataset Rain in Australia, termasuk penelitian ini, mengklasifikasikan mekanisme missing value (MCAR, MAR, MNAR) secara teoretis dan deskriptif tanpa melakukan pengujian statistik formal. Padahal, analisis temporal pada dataset ini menunjukkan bahwa tingkat missing value variabel Sunshine meningkat secara konsisten dari 0% pada tahun 2007 hingga mencapai 74% pada tahun 2017, sebuah pola yang mengindikasikan kemungkinan mekanisme Missing Not at Random (MNAR) atau setidaknya Missing at Random (MAR) yang bergantung pada waktu. Näf et al. (2025) mengembangkan uji MCAR non-parametrik berbasis Random Forest dan Kullback-Leibler Divergence, yang disebut sebagai PKLM Test, yang mampu mendeteksi pola ini secara formal bahkan pada data berdimensi tinggi dengan sedikit observasi lengkap. Jaisankar et al. (2025) dalam tinjauan metodologi statistis mereka juga menegaskan bahwa pengujian mekanisme missing secara formal merupakan prasyarat krusial sebelum pemilihan metode imputasi, karena kesalahan asumsi mekanisme dapat menghasilkan estimasi yang bias. Penelitian selanjutnya perlu mengintegrasikan pengujian formal ini ke dalam pipeline preprocessing agar pemilihan strategi imputasi memiliki landasan statistis yang lebih kuat.

2. Diabaikannya dimensi spasial dan temporal dalam strategi imputasi

Penelitian ini dan penelitian-penelitian sebelumnya menggunakan pendekatan imputasi global, yaitu satu imputer dilatih pada seluruh dataset tanpa mempertimbangkan perbedaan karakteristik antar lokasi geografis. Padahal, analisis eksplorasi pada dataset ini mengungkapkan variasi spasial yang ekstrem: beberapa kota seperti Albury, BadgerysCreek, dan Ballarat memiliki tingkat missing hingga 100% untuk variabel Sunshine dan Evaporation, sementara kota seperti Brisbane memiliki missing rate mendekati 0% untuk variabel yang sama. Bernal-Zubieta et al. (2025) dalam review komprehensif mereka menyimpulkan bahwa metode machine learning dan teknik hybrid yang mempertimbangkan korelasi spasial dan temporal secara eksplisit terbukti berkinerja jauh lebih baik dibandingkan metode konvensional untuk data cuaca yang bersifat spasiotemporal. Saubhagya et al. (2024) mengusulkan pendekatan hybrid yang mengintegrasikan Multi-Layer Perceptron untuk menangkap variabilitas temporal dengan Spatial Kriging untuk memodelkan hubungan spasial antar stasiun, dan terbukti

mengungguli pendekatan murni temporal maupun spasial secara terpisah. Celah ini menunjukkan perlunya eksplorasi strategi imputasi berbasis lokasi atau regional pada dataset Rain in Australia.

3. Keterbatasan generalisasi akibat penggunaan satu jenis classifier

Penelitian ini membatasi evaluasi hanya pada satu algoritma klasifikasi, yaitu Random Forest, sehingga tidak dapat diketahui apakah ranking strategi imputasi yang diperoleh bersifat konsisten lintas algoritma. Shadbahr et al. (2023) dalam studi yang dipublikasikan di Communications Medicine menggunakan ANOVA multifaktor dan menunjukkan bahwa interaksi antara tingkat missing, metode imputasi, dan jenis classifier secara bersama-sama mempengaruhi performa downstream classification secara signifikan, sehingga hasil yang diperoleh dari satu classifier tidak dapat digeneralisasi ke classifier lain. Senada dengan itu, Aracri et al. (2025) pada data neuroimaging Alzheimer secara empiris membuktikan bahwa metode imputasi terbaik tidak bersifat universal dan berubah tergantung pada algoritma klasifikasi yang dipasangkan, dengan MICE mengungguli missForest pada Logistic Regression namun menunjukkan pola berbeda pada Random Forest. Penelitian lanjutan perlu melibatkan setidaknya XGBoost dan Logistic Regression sebagai pembanding agar kesimpulan rekomendasi imputasi memiliki cakupan generalisasi yang lebih luas.

4. Tidak adanya analisis sensitivitas terhadap variasi tingkat missing

Eksperimen dalam penelitian ini dilakukan pada kondisi missing yang ada di dalam dataset tanpa simulasi tingkat missing yang dikontrol secara sistematis. Akibatnya, tidak dapat diidentifikasi pada ambang batas missing rate berapa suatu metode imputasi mulai mengungguli yang lain. Gabr et al. (2023) telah mendemonstrasikan bahwa sensitivitas classifier terhadap missing data bervariasi secara signifikan tergantung pada rasio missing yang digunakan, serta faktor kontekstual lain seperti ukuran dataset dan tingkat keseimbangan kelas. Mello-Román et al. (2025) memperkuat temuan ini dengan menguji empat metode imputasi pada lima level missing yang berbeda dan menemukan bahwa peringkat performa antar metode dapat bergeser secara substansial ketika tingkat missing meningkat. Analisis sensitivitas semacam ini khususnya relevan untuk dataset Rain in Australia mengingat tingkat missing yang sangat bervariasi antar variabel, mulai dari 0,87% hingga 48%.

Dengan mempertimbangkan keempat gap di atas, penelitian ini berkontribusi pada Gap 1 dan Gap 2 dengan menyediakan analisis eksploratif pola missing secara spasial dan temporal, serta eksperimen komparasi lima strategi imputasi yang terkontrol dan bebas data leakage. Kontribusi utama penelitian ini adalah menghasilkan rekomendasi berbasis bukti empiris mengenai strategi imputasi yang paling efektif untuk dataset cuaca Australia. Gap 3 dan Gap 4 secara eksplisit diakui sebagai keterbatasan dan diusulkan sebagai arah penelitian selanjutnya.

3. Metodologi

3.1 Alur Penelitian

Penelitian ini dirancang dengan mengikuti alur kerja yang sistematis dan dapat direplikasi (reproducible). Tahapan penelitian diawali dengan Pengumpulan Data, yang kemudian dilanjutkan dengan tahap Eksplorasi Data Awal (EDA). Pada tahap EDA, dilakukan perhitungan statistik deskriptif, analisis distribusi kelas target, serta visualisasi pola data yang hilang (missing value) untuk memahami karakteristik fundamental dari dataset.

Setelah memahami karakteristik data, tahapan selanjutnya adalah Pra-pemrosesan Awal (Preprocessing), yang mencakup proses encoding pada fitur kategorik dan variabel target. Guna mencegah terjadinya kebocoran data (data leakage), pemisahan data latih dan data uji (Train-Test Split) dengan rasio 80:20 wajib dilakukan secara ketat sebelum proses penanganan data kosong. Langkah ini memastikan bahwa model akan dievaluasi pada data yang benar-benar independen.

Tahap krusial berikutnya adalah Imputasi Missing Value, di mana proses fitting imputer dilakukan secara eksklusif hanya pada data latih (X_{train}). Penelitian ini membandingkan lima skenario penanganan data kosong, yaitu: model Baseline (menggunakan metode Listwise Deletion atau Drop NA), Mean Imputation, Median Imputation, K-Nearest Neighbor (KNN) Imputer ($k=5$), dan Multivariate Imputation by Chained Equations (MICE) menggunakan IterativeImputer.

Seluruh dataset dari masing-masing skenario tersebut kemudian digunakan untuk melatih model Random Forest Classifier. Pengaturan `random_state=42` diterapkan guna menjamin konsistensi eksperimen. Selanjutnya, kinerja model diukur pada tahap Evaluasi menggunakan Test Set dengan metrik standar yang mencakup Accuracy, Precision, Recall, F1-Score, dan AUC-ROC. Seluruh tahapan ini bermuara pada proses Analisis dan Kesimpulan untuk membedah efektivitas masing-masing metode imputasi secara komprehensif.

Tabel 3.1 Ringkasan Skenario Eksperimen

No	Skenario	Mekanisme	Catatan
1	Drop NA (Baseline)	Menghapus seluruh baris dengan nilai kosong. Tidak ada imputasi.	Sebagai pembanding batas bawah performa
2	Mean Imputation	Mengganti nilai kosong dengan rata-rata kolom. Fit hanya pada X_{train} .	Sederhana, rentan bias pada data skewed
3	Median Imputation	Mengganti nilai kosong dengan median kolom. Fit hanya pada X_{train} .	Lebih robust terhadap outlier vs Mean
4	KNN Imputer ($k=5$)	Menggunakan $k=5$ tetangga terdekat berbasis jarak Euclidean. Fit hanya pada X_{train} .	Tanpa normalisasi, lihat Batasan 7
5	MICE (IterativeImputer)	Regresi berantai iteratif. Fit hanya pada X_{train} . <code>max_iter=10</code> , <code>random_state=42</code> .	Kompleks, namun mampu memodelkan dependensi multivariat

3.2 Deskripsi Dataset

Dataset yang digunakan adalah Rain in Australia, sebuah dataset cuaca publik yang mengumpulkan observasi meteorologi harian dari 49 stasiun cuaca yang tersebar di seluruh Australia selama periode lebih dari satu dekade. Dataset ini tersedia melalui platform Kaggle dan merupakan adaptasi dari data resmi Bureau of Meteorology Australia.

Karakteristik utama dataset adalah:

- Jumlah observasi: 145.460 baris
- Jumlah fitur: 22 kolom (setelah kolom target)
- Fitur numerik: MinTemp, MaxTemp, Rainfall, Evaporation, Sunshine, WindGustSpeed, WindSpeed9am, WindSpeed3pm, Humidity9am, Humidity3pm, Pressure9am, Pressure3pm, Cloud9am, Cloud3pm, Temp9am, Temp3pm
- Fitur kategorik: Date, Location, WindGustDir, WindDir9am, WindDir3pm, RainToday
- Variabel target: RainTomorrow (biner: 'Yes' / 'No')
- Distribusi kelas: ~78% 'No', ~22% 'Yes' (ketidakseimbangan kelas moderat)
- Tingkat missing value: Bervariasi dari 0.87% (MaxTemp) hingga ~48% (Sunshine)

3.3 Skenario Eksperimen Bebas Data Leakage

Prinsip terpenting dalam desain eksperimen ini adalah eliminasi total data leakage. Dalam banyak implementasi yang kurang hati-hati, imputer di-fit pada keseluruhan dataset sebelum pembagian train-test, sehingga statistik dari data uji (yang seharusnya tidak diketahui model) "bocor" ke dalam data latih. Hal ini menghasilkan evaluasi yang terlalu optimistis dan tidak representatif terhadap performa model di dunia nyata.

Pada penelitian ini, protokol ketat berikut diberlakukan:

- `train_test_split(X, y, test_size=0.2, random_state=42)` dilakukan pada data mentah (setelah encoding kategorik).
- Setiap imputer (Mean, Median, KNN, MICE) di-fit menggunakan `imputer.fit(X_train_raw)`, hanya mempelajari statistik dari data latih.
- Transformasi kemudian diterapkan pada `X_train` dan `X_test` secara terpisah menggunakan `imputer.transform()`.
- Model Random Forest dilatih pada `X_train` yang telah diimputasi dan dievaluasi pada `X_test` yang telah diimputasi.

Dengan demikian, test set benar-benar berperan sebagai data "tak terlihat" (unseen data) yang mencerminkan kondisi deployment di dunia nyata.

4. Hasil dan Pembahasan

4.1 Eksplorasi Data Awal (EDA) dan Distribusi

Sebelum memasuki tahap pemodelan, dilakukan eksplorasi data awal (*Exploratory Data Analysis/EDA*) yang bertujuan memahami struktur, distribusi, dan karakteristik dataset secara menyeluruh. Tahap ini merupakan praktik standar dalam pipeline KDD sebagaimana direkomendasikan oleh Fayyad et al. (1996), karena keputusan-keputusan kritis mengenai strategi *preprocessing*, termasuk strategi penanganan *missing value* yang sangat bergantung pada pemahaman mendalam terhadap data itu sendiri.

Aspek yang dieksplorasi pada tahap ini mencakup: (1) statistik deskriptif setiap variabel, (2) distribusi variabel target *RainTomorrow* yang mengindikasikan tingkat ketidakseimbangan kelas, dan (3) visualisasi pola *missing value* menggunakan library *missingno* untuk mengidentifikasi apakah kehilangan data bersifat acak atau terstruktur.

4.1.1 Implementasi Kode: Import Library dan Pemuatan Dataset

Implementasi program diawali dengan mengimpor seluruh *library* yang dibutuhkan. Library *numpy* dan *pandas* digunakan untuk manipulasi dan komputasi data, sementara *matplotlib*, *seaborn*, dan *missingno* digunakan untuk keperluan visualisasi. Untuk tahap *preprocessing*, digunakan *LabelEncoder* dan *train_test_split* dari *scikit-learn*. Keperluan imputasi dipenuhi oleh *SimpleImputer*, *KNNImputer*, dan *IterativeImputer* (MICE), sedangkan model klasifikasi menggunakan *RandomForestClassifier* beserta berbagai fungsi metrik evaluasi seperti *accuracy_score*, *f1_score*, dan *roc_auc_score*. Perlu diperhatikan bahwa sebelum mengimpor *IterativeImputer*, harus terlebih dahulu diaktifkan melalui baris *enable_iterative_imputer* karena fitur ini masih berstatus eksperimental di *scikit-learn*.

Dataset kemudian dimuat dari tautan GitHub Raw menggunakan fungsi *pd.read_csv()* dan disimpan ke variabel *df_raw*. Setelah pemuatan berhasil, program mencetak dimensi dataset untuk konfirmasi awal. Output yang dihasilkan memastikan dataset terdiri dari 145.460 baris dan 23 kolom, sesuai dengan spesifikasi dataset *Rain in Australia* yang digunakan dalam penelitian ini.

4.1.2 Implementasi Kode: Eksplorasi Data (EDA Umum)

Tahap EDA diimplementasikan dalam satu blok kode terpadu yang terdiri dari tiga bagian utama. Pertama, program memanggil *df_raw.info()* untuk mencetak ringkasan tipe data dan jumlah nilai non-null pada setiap kolom. Output ini memberikan gambaran awal mengenai kolom-kolom mana saja yang mengandung *missing values*. Kedua, fungsi *df_raw.describe()* digunakan untuk menampilkan statistik deskriptif seluruh fitur numerik, meliputi nilai minimum, maksimum, rata-rata, standar deviasi, serta kuartil pertama, kedua, dan ketiga.

Ketiga, dilakukan analisis kuantitatif *missing value* per kolom. Program menghitung jumlah dan persentase nilai kosong menggunakan *df_raw.isnull().sum()*, kemudian menggabungkan hasilnya ke dalam sebuah *DataFrame* *missing_df* yang diurutkan secara menurun berdasarkan persentase kehilangan. Tabel tersebut hanya

menampilkan kolom yang benar-benar memiliki nilai kosong, sehingga memudahkan identifikasi variabel-variabel yang paling terdampak. Hasil analisis ini terangkum pada Tabel 4.1 berikut.


Tabel 4.1 Ringkasan Missing Value Per Kolom (Format Tabel)

Kolom	Jumlah Missing	Persentase (%)
Sunshine	69,835	48.01%
Evaporation	62,790	43.17%
Cloud3pm	59,358	40.81%
Cloud9am	55,888	38.42%
Pressure9am	15,065	10.36%
Pressure3pm	15,028	10.33%
WindDir9am	10,566	7.26%
WindGustDir	10,326	7.10%
WindGustSpeed	10,263	7.06%
Humidity3pm	4,507	3.10%
WindDir3pm	4,228	2.91%
Temp3pm	3,609	2.48%
Rainfall	3,261	2.24%
RainToday	3,261	2.24%
WindSpeed3pm	3,062	2.11%
Humidity9am	2,654	1.82%
WindSpeed9am	1,767	1.21%
Temp9am	1,767	1.21%
MinTemp	1,485	1.02%
MaxTemp	1,261	0.87%

Berdasarkan Tabel 4.1, terdapat 19 dari 23 kolom yang mengandung nilai kosong, menegaskan bahwa penanganan *missing value* merupakan tahap yang sangat krusial dan tidak dapat diabaikan dalam penelitian ini.

4.1.3 Visualisasi Distribusi Variabel Target

Kode visualisasi pertama menghasilkan dua panel grafis yang menggambarkan distribusi kelas target RainTomorrow. Panel kiri menampilkan *bar chart* frekuensi absolut masing-masing kelas, sementara panel kanan menampilkan *pie chart* untuk proporsi relatifnya. Setiap batang pada *bar chart* diberi anotasi dengan jumlah observasi dan persentasenya. Visualisasi ini dibuat menggunakan `matplotlib.pyplot.subplots()` dengan ukuran kanvas 14x5 inci dan disimpan ke file `fig1_target_distribution.png`.




Gambar 4.1 Distribusi Kelas Target *RainTomorrow*

Output Gambar 4.1 memperlihatkan ketidakseimbangan kelas yang cukup nyata: kelas 'No' (tidak hujan) mendominasi dengan sekitar 78% dari seluruh observasi, sementara kelas 'Yes' (hujan) hanya mencakup sekitar 22%. Kondisi *class imbalance* ini menjadi salah satu alasan utama pemilihan F1-Score dan AUC-ROC sebagai metrik evaluasi, karena akurasi sederhana tidak mampu menggambarkan performa model secara representatif pada kondisi ini.


4.1.4 Visualisasi Pola Missing Value dengan Missingno

Blok kode berikutnya menghasilkan dua visualisasi pola *missing value* menggunakan library missingno. Visualisasi pertama adalah `msno.bar()` yang menampilkan proporsi data yang tersedia (non-null) untuk setiap kolom dalam bentuk batang vertikal. Kolom dengan batang penuh berarti tidak ada nilai kosong, sementara batang yang lebih pendek mengindikasikan tingkat kehilangan yang lebih tinggi.



Gambar 4.2 Missingno Bar Chart Proporsi Data Non-Null

Visualisasi kedua adalah `msno.heatmap()` yang menampilkan korelasi antar pola *missing value* dari pasangan variabel. Nilai korelasi mendekati +1 berarti ketika satu variabel memiliki nilai kosong, variabel lainnya juga cenderung kosong secara bersamaan; nilai mendekati -1 menunjukkan pola yang berlawanan; dan nilai mendekati 0 mengindikasikan pola kehilangan yang independen satu sama lain.



Gambar 4.3 Missingno Heatmap Korelasi Pola Missing Value

4.2 Interpretasi Pola Missing Value

Berdasarkan hasil visualisasi EDA di atas, dapat dilakukan analisis mendalam terhadap karakteristik *missing value* dalam dataset Rain in Australia dari beberapa dimensi.

- **Distribusi Variabel Target**

Dataset ini menampilkan *class imbalance* yang cukup nyata, dengan sekitar 78% observasi berlabel 'No' dan 22% berlabel 'Yes'. Kondisi ini menegaskan mengapa F1-Score dan AUC-ROC dipilih sebagai metrik evaluasi utama, alih-alih akurasi sederhana yang dapat memberikan gambaran menyesatkan.

- **Analisis Kuantitatif Missing Value**

Terdapat variasi tingkat kehilangan data yang sangat besar antar kolom (lihat Tabel 4.1). Variabel Sunshine (~48%) dan Evaporation (~43%) memiliki tingkat missing tertinggi, sementara Cloud9am (~38%) dan Cloud3pm (~41%) juga mengandung proporsi yang sangat signifikan. Di sisi lain, variabel seperti MinTemp, MaxTemp, dan beberapa fitur kecepatan angin hanya kehilangan kurang dari 2% datanya.

- **Identifikasi Mekanisme Missing Value**

Observasi terhadap Missingno Heatmap (Gambar 4.3) mengungkapkan pola yang sangat instruktif. Terdapat korelasi positif yang tinggi antara pola missing pada Cloud9am dan Cloud3pm, demikian pula antara Pressure9am dan Pressure3pm. Hal ini mengindikasikan bahwa ketika data pengamatan pagi hari hilang dari suatu stasiun, data pengamatan sore harinya pun cenderung hilang secara bersamaan. Pola ini mengisyaratkan bahwa mekanisme kehilangan data tidak sepenuhnya acak, melainkan bergantung pada kondisi operasional stasiun cuaca yang terobservasi melalui variabel lain, karakteristik yang paling sesuai dengan kategori MAR (Missing at Random),

meskipun elemen MNAR pun tidak dapat dikesampingkan untuk variabel seperti Sunshine yang mungkin gagal tercatat justru saat kondisi cuaca sangat berawan.

Identifikasi mekanisme MAR ini memiliki implikasi metodologis yang penting: metode imputasi yang memanfaatkan korelasi antar variabel terobservasi, seperti KNN dan MICE yang secara teoretis lebih sesuai dan diharapkan menghasilkan estimasi yang lebih akurat dibandingkan imputasi univariat sederhana.

4.3 Preprocessing: Encoding dan Train-Test Split

4.3.1 Implementasi Kode: Encoding Fitur Kategorik

Setelah eksplorasi awal, dilakukan tahap preprocessing awal yang mencakup encoding fitur kategorik. Kode diawali dengan membuat salinan dataset menggunakan `df_raw.copy()`, kemudian menghapus kolom Date karena informasi temporal perlu dikonversi terlebih dahulu dan berada di luar lingkup penelitian ini. Langkah krusial berikutnya adalah menghapus baris di mana variabel target RainTomorrow bernilai NaN sebelum proses encoding dilakukan, guna mencegah nilai 'nan' ikut ter-encode sebagai kelas ketiga yang tidak valid.

Seluruh kolom kategorik selain target kemudian dikonversi ke tipe string dan diencode menggunakan LabelEncoder dari scikit-learn. Nilai NaN pada fitur-fitur tersebut akan muncul sebagai string 'nan' yang kemudian dapat dikenali dan diimputasi pada tahap berikutnya. Variabel target RainTomorrow diencode secara eksplisit menggunakan pemetaan manual: 'No' menjadi 0 dan 'Yes' menjadi 1, karena pendekatan ini lebih aman dan lebih terkontrol dibandingkan menggunakan LabelEncoder secara langsung pada variabel target biner.

4.3.2 Implementasi Kode: Train-Test Split

Tahap train-test split merupakan langkah yang wajib dilakukan sebelum proses imputasi apa pun, karena ini adalah inti dari prinsip zero data leakage yang menjadi fondasi desain eksperimen penelitian ini. Sebelum pemisahan, baris-baris dengan nilai target yang masih NaN difilter terlebih dahulu menggunakan `y.notna()`, menghasilkan dataset yang sepenuhnya valid untuk dilatihkan ke model.

Pemisahan data dilakukan dengan rasio 80:20 (data latih:data uji) menggunakan `train_test_split()` dari scikit-learn, dengan parameter `random_state=42` untuk menjamin reproduisibilitas dan `stratify=y_valid` untuk memastikan proporsi kelas 'Yes' dan 'No' terjaga secara seimbang baik di data latih maupun data uji.

Tabel 4.2 Hasil Train-Test Split Dataset

Subset Data	Jumlah Sampel	Proporsi 'No' (%)	Proporsi 'Yes' (%)
X_train_raw	113.754	~77,9	~22,1
X_test_raw	28.439	~77,9	~22,1

4.4 Implementasi Lima Skenario Imputasi Missing Value

Setelah split data selesai, tahap inti penelitian ini dilaksanakan: mengimplementasikan dan membandingkan lima skenario penanganan missing value. Prinsip fundamental yang diterapkan adalah seluruh imputer hanya di-fit pada `X_train_raw`, kemudian di-transform secara terpisah pada `X_train_raw` dan `X_test_raw`. Dengan demikian, statistik dari data uji tidak pernah 'bocor' ke dalam proses pembelajaran imputasi.

4.4.1 Metode 0: Baseline (Drop NA)

Skenario Baseline tidak menggunakan imputer sama sekali. Semua baris yang mengandung setidaknya satu nilai kosong dihapus secara langsung dari masing-masing subset data menggunakan `DataFrame.dropna()`. Indeks target (`y_train` dan `y_test`) kemudian difilter agar sesuai dengan indeks baris yang tersisa. Operasi ini dilakukan secara independen pada `X_train_raw` dan `X_test_raw` sehingga tidak ada informasi yang dibagi antar kedua subset.

Konsekuensi dari pendekatan ini adalah pengurangan jumlah sampel yang sangat signifikan. Dari 113.754 sampel latih, hanya sekitar 46.466 sampel yang tersisa setelah penghapusan (sekitar 40,8% dari total). Ini berarti lebih dari separuh data latih dibuang, namun sampel yang tersisa adalah observasi yang paling lengkap dan yang seperti akan dibahas pada subbab 4.5, memiliki karakteristik yang cenderung lebih mudah dimodelkan.

4.4.2 Metode 1: Mean Imputation

Mean Imputation menggunakan `SimpleImputer(strategy='mean')` dari `scikit-learn`. Imputer di-fit pada `X_train_raw` untuk menghitung nilai rata-rata setiap kolom dari data latih, kemudian nilai rata-rata tersebut digunakan untuk mengisi semua nilai kosong pada `X_train` maupun `X_test`. Durasi komputasi untuk tahap ini tercatat sangat cepat. Output konfirmasi mencetak bahwa sisa missing value pada `X_train` setelah imputasi adalah 0 (nol), menandakan bahwa seluruh nilai kosong berhasil diisi.

4.4.3 Metode 2: Median Imputation

Median Imputation menggunakan `SimpleImputer(strategy='median')`. Mekanismenya identik dengan Mean Imputation, namun statistik yang digunakan adalah nilai tengah (median) alih-alih rata-rata. Pendekatan ini lebih robust terhadap keberadaan outlier dalam data, karena median tidak terpengaruh oleh nilai-nilai ekstrem yang jauh di luar rentang distribusi normal. Pada dataset cuaca yang rentan terhadap nilai ekstrem (misalnya curah hujan yang sangat tinggi saat badai), ini menjadi keunggulan komparatif yang bermakna.

4.4.4 Metode 3: KNN Imputer (k=5)

KNN Imputer menggunakan `KNNImputer(n_neighbors=5, weights='uniform')` dari `scikit-learn`. Berbeda dengan dua metode sebelumnya yang bersifat univariat (hanya mempertimbangkan distribusi satu kolom), KNN Imputer bersifat multivariat karena mencari 5 tetangga terdekat dalam ruang fitur multi-dimensi berdasarkan jarak

Euclidean, kemudian menggunakan rata-rata tertimbang nilai tetangga-tetangga tersebut untuk mengisi nilai yang hilang.

Proses fitting dan transformasi KNN Imputer membutuhkan waktu komputasi yang jauh lebih lama dibandingkan Mean dan Median Imputation karena kompleksitas perhitungan jarak antar sampel yang berskala $O(n^2)$. Perlu dicatat bahwa dalam penelitian ini, normalisasi fitur tidak dilakukan sebelum KNN Imputation agar seluruh skenario berada pada kondisi preprocessing yang seragam dan perbedaan performa murni mencerminkan perbedaan strategi imputasi. Konsekuensinya adalah potensi dominasi fitur berskala besar seperti Pressure (nilai >1000) terhadap perhitungan jarak Euclidean, yang diakui sebagai keterbatasan penelitian ini.


4.4.5 Metode 4: MICE (IterativeImputer)

MICE diimplementasikan menggunakan Iterative Imputer(max_iter=10, random_state=42) dari scikit-learn (perlu diaktifkan terlebih dahulu melalui enable_iterative_imputer). MICE adalah metode imputasi multivariat yang paling canggih di antara kelima skenario. Ia bekerja melalui serangkaian regresi berantai: pada setiap iterasi, setiap variabel yang memiliki missing value dimodelkan sebagai fungsi dari seluruh variabel lain, dan nilai yang hilang diimputasi dari model regresi tersebut. Proses ini diulang hingga 10 iterasi (max_iter=10) atau hingga konvergensi tercapai.

Waktu komputasi MICE adalah yang paling lama di antara semua metode (sekitar 48,65 detik), mencerminkan kompleksitas iteratif dari pendekatannya. Namun, keunggulan teoritis MICE terletak pada kemampuannya memodelkan dependensi multivariat yang kompleks secara implisit, menghasilkan nilai imputasi yang paling 'realistis' secara statistik.

4.5 Visualisasi Perbandingan Before vs After Imputasi

Untuk memberikan pemahaman intuitif mengenai dampak masing-masing strategi imputasi terhadap distribusi data, dilakukan visualisasi perbandingan kolom Humidity3pm sebelum dan sesudah imputasi. Kolom ini dipilih karena memiliki tingkat missing value yang cukup signifikan (~2,87%) namun tidak terlalu ekstrem, sehingga perbedaan antar metode dapat diamati secara lebih jelas. Visualisasi dibuat menggunakan plt.subplots(2, 3) berukuran 18×10 inci yang menampilkan enam panel: satu panel 'Before' dan lima panel 'After' untuk setiap metode imputasi.



Gambar 4.4 Distribusi Kolom Humidity3pm Sebelum dan Sesudah Imputasi

4.5.1 Interpretasi Grafis Before vs After Imputasi

Visualisasi distribusi kolom Humidity3pm sebelum dan sesudah imputasi memberikan gambaran yang informatif mengenai dampak masing-masing strategi terhadap karakteristik statistik data.

- **Before (Data Original)**

Distribusi menunjukkan pola yang relatif smooth dan mencerminkan variasi alamiah kelembapan udara.

- **Mean Imputation**

Paling mencolok adalah munculnya spike (lonjakan frekuensi yang sangat tajam) tepat pada nilai rata-rata kolom tersebut. Ini adalah artefak klasik dari imputasi mean: semua nilai yang hilang digantikan dengan satu nilai identik, membentuk massa probabilitas yang terkonsentrasi artifisial. Distribusi menjadi terdistorsi dan standar deviasi menurun secara tidak realistis, fenomena yang dikenal sebagai variance deflation.

- **Median Imputation**

Pola yang sama dengan mean imputation, namun spike terletak pada nilai median. Meskipun median lebih robust terhadap outlier, masalah fundamental mengenai variance deflation tetap terjadi karena pendekatan univariat yang digunakan.

- **KNN Imputation**

Distribusi tampak lebih mulus dan lebih mendekati distribusi data original karena nilai imputasi berasal dari tetangga yang secara kontekstual serupa. Spike artifisial tidak muncul dan standar deviasi terjaga lebih baik.

- **MICE Imputation**

Secara visual menghasilkan distribusi yang paling mendekati distribusi original, dengan skewness dan kurtosis yang lebih terpelihara. Hal ini konsisten dengan kelebihan teoritis MICE yang memodelkan distribusi kondisional setiap variabel secara iteratif, menghasilkan imputasi yang paling "realistis" secara statistik.

Temuan visual ini secara langsung mendukung hipotesis bahwa metode multivariat (KNN, MICE) lebih mampu mempertahankan struktur statistik data dibandingkan metode univariat (Mean, Median). Namun demikian, seperti akan ditunjukkan pada subbab berikutnya, keunggulan visual ini tidak selalu berkorelasi langsung dengan keunggulan performa model klasifikasi.

4.6 Training Random Forest dan Evaluasi Performa

4.6.1 Implementasi Kode: Pipeline Training

Training model dilakukan dalam satu blok kode yang sistematis menggunakan struktur data daftar (list) yang disebut scenarios. Setiap elemen dalam daftar ini berisi nama metode, pasangan data latih-uji (X_{train} , X_{test}), dan pasangan label latih-uji (y_{train} , y_{test}) yang sesuai. Program kemudian melakukan iterasi melalui kelima

skenario, melatih RandomForestClassifier(`n_estimators=100`, `random_state=42`, `n_jobs=-1`) pada setiap skenario, dan menghitung semua metrik evaluasi.

Untuk setiap skenario, prediksi kelas diperoleh melalui `rf.predict()` dan probabilitas prediksi diperoleh melalui `rf.predict_proba()`. Metrik yang dihitung meliputi Accuracy, Precision, Recall, F1-Score (weighted), dan AUC-ROC. Untuk AUC-ROC, program secara otomatis mendeteksi apakah masalah bersifat biner atau multiclass dan menggunakan formula yang sesuai. Waktu eksekusi dicatat menggunakan `time.time()` untuk mengukur efisiensi komputasi masing-masing metode. Seluruh hasil kemudian disimpan ke dalam DataFrame `df_results` untuk keperluan analisis dan visualisasi lanjutan.

4.6.2 Tabel Perbandingan Hasil Evaluasi

Berikut adalah hasil perbandingan performa kelima metode penanganan missing value yang dirangkum dalam Tabel 4.3. Nilai F1-Score dan AUC-ROC menjadi metrik utama pembandingan mengingat kondisi class imbalance pada dataset ini.


Tabel 4.3 Perbandingan Performa Kelima Metode Imputasi pada Random Forest Classifier

Metode	N Train	N Test	Accuracy	Precision	Recall	F1-Score	AUC-ROC	Waktu (s)
Baseline (Drop NA)	~46.466	~11.576	0,8618	0,8587	0,8618	0,8530	0,8979	~12,3
Mean Imputation	113.754	28.439	0,8573	0,8542	0,8573	0,8459	0,8884	~30,5
Median Imputation	113.754	28.439	0,8580	0,8548	0,8580	0,8463	0,8882	~30,9
KNN Imputer (k=5)	113.754	28.439	0,8563	0,8528	0,8563	0,8448	0,8847	~75
MICE (Iterative Imputer)	113.754	28.439	0,8573	0,8543	0,8573	0,8459	0,8869	~48,7

Nilai pada tabel merupakan hasil representatif dari eksperimen. N Train untuk Baseline lebih kecil karena penghapusan baris yang mengandung missing value. Waktu KNN mencakup proses fitting dan transformasi pada dataset berukuran penuh.


4.6.3 Visualisasi Perbandingan Metrik

Kode visualisasi berikutnya menghasilkan grafik batang yang membandingkan F1-Score dan AUC-ROC dari kelima metode secara berdampingan. Setiap batang diberi anotasi nilai numeriknya untuk memudahkan pembacaan. Metode terbaik pada masing-masing metrik disorot dengan warna berbeda.



Gambar 4.5 Perbandingan F1-Score dan AUC-ROC Kelima Metode Imputasi

Selain itu, program menghasilkan visualisasi Heatmap Perbandingan Semua Metrik Evaluasi menggunakan `sns.heatmap()`. Heatmap ini menampilkan kelima metode imputasi pada sumbu vertikal dan kelima metrik evaluasi (Accuracy, Precision, Recall, F1-Score, AUC-ROC) pada sumbu horizontal. Setiap sel diberi anotasi nilai numeriknya hingga empat desimal, dengan gradasi warna dari kuning (nilai lebih rendah) hingga merah (nilai lebih tinggi) sehingga pola perbedaan performa antar metode dapat langsung teridentifikasi secara visual.



Gambar 4.6 Heatmap Perbandingan Semua Metrik Evaluasi Kelima Metode Imputasi

4.7 Pembahasan Mendalam Hasil Eksperimen

4.7.1 Temuan Empiris: Baseline Unggul dan Implikasinya

Hasil eksperimen menghasilkan temuan yang secara sekilas tampak berlawanan dengan ekspektasi teoretis, namun sesungguhnya mengandung pelajaran metodologis yang sangat berharga. Alih-alih metode multivariat (KNN, MICE) yang diperkirakan unggul, justru metode Baseline (Drop NA) mencatat performa tertinggi pada seluruh metrik, dengan F1-Score sebesar 0,8530 dan AUC-ROC sebesar 0,8979. Di bawahnya berturut-turut: Median (F1: 0,8463, AUC: 0,8882), Mean (F1: 0,8459, AUC: 0,8884), MICE (F1: 0,8459, AUC: 0,8869), dan KNN yang mencatat F1-Score terendah sebesar 0,8448 serta AUC-ROC 0,8847.

Fenomena ini tidak serta-merta menyanggah teori imputasi multivariat. Penjelasan yang paling plausibel terletak pada mekanisme seleksi data implisit yang terjadi ketika penghapusan baris diterapkan. Dataset Rain in Australia memiliki missing values yang terkonsentrasi pada variabel-variabel dengan nilai meteorologis yang secara fisika lebih sulit diukur seperti Sunshine (~48% missing) dan Evaporation (~43%

missing) yang cenderung tidak tersedia justru pada kondisi cuaca ekstrem atau tidak biasa. Ketika baris-baris ini dihapus, yang tersisa adalah observasi dari kondisi cuaca yang lebih 'normal' dan terukur secara lengkap, sehingga polanya lebih mudah dipelajari oleh Random Forest. Dengan kata lain, Baseline secara tidak sengaja melakukan quality filtering yang menghasilkan subset data berkualitas tinggi, meskipun dengan mengorbankan lebih dari separuh observasi.

Temuan ini menegaskan bahwa superioritas suatu metode imputasi sangat bergantung pada mekanisme missing value yang sesungguhnya berlaku. Ketika missing data cenderung bersifat MNAR (Missing Not at Random) di mana nilai hilang bukan karena faktor acak melainkan karena kondisi yang berkorelasi dengan nilai itu sendiri penghapusan data paradoksnya dapat menghasilkan subset yang lebih 'bersih' dan lebih mudah dimodelkan. Hal ini konsisten dengan temuan Allison (2001) bahwa listwise deletion dapat menghasilkan estimasi yang efisien apabila mekanisme missing-nya memang MNAR pada variabel dependen.

4.7.2 Perbandingan Antar Metode Imputasi

Di antara keempat metode imputasi (yang tidak membuang data), perbedaan performa bersifat marjinal namun tetap bermakna secara metodologis. Mean dan MICE berbagi F1-Score yang identik sebesar 0,8459, Median sedikit lebih unggul dengan 0,8463, sementara KNN menjadi yang terendah dengan 0,8448. Pada AUC-ROC, Mean (0,8884) sedikit mengungguli Median (0,8882), MICE (0,8869), dan KNN (0,8847).

Kesetaraan performa antara Mean metode paling sederhana dengan MICE yang jauh lebih kompleks memberikan implikasi penting. Dalam konteks dataset ini, kompleksitas komputasi tambahan yang ditanggung MICE (~48,65 detik) dibandingkan Mean (~30,5 detik) tidak memberikan keuntungan performa yang signifikan. Ini mengisyaratkan bahwa Random Forest, sebagai algoritma berbasis pohon keputusan yang secara inheren mampu menangani data yang tidak linier dan tidak normal, cukup robust terhadap kualitas imputasi yang digunakan setidaknya dalam rentang yang diuji pada penelitian ini.

Rendahnya performa relatif KNN Imputer, berlawanan dengan ekspektasi teoritis, kemungkinan besar disebabkan oleh absennya normalisasi fitur sebelum perhitungan jarak Euclidean. Fitur Pressure9am dan Pressure3pm yang bernilai di atas 1.000 mendominasi perhitungan jarak, sehingga 'tetangga terdekat' yang ditemukan KNN tidak selalu merupakan tetangga yang paling relevan secara meteorologis.

4.7.3 Trade-off Performa vs Kelengkapan Data

Salah satu dimensi analisis yang paling penting namun sering diabaikan dalam komparasi metode imputasi adalah trade-off antara performa model dan kelengkapan cakupan prediksi. Metode Baseline memang mencapai performa tertinggi, namun dengan biaya yang sangat signifikan: model hanya dilatih pada ~40,8% data dan hanya dapat memprediksi observasi uji yang juga memiliki data lengkap. Dalam skenario deployment nyata di mana prediksi harus dibuat bahkan untuk hari-hari dengan data

sensor yang tidak lengkap (misalnya saat badai ketika beberapa sensor mati), model Baseline akan gagal total karena tidak dapat menangani input yang mengandung missing values.

Sementara itu, keempat metode imputasi lainnya mempertahankan seluruh 113.754 sampel latih dan mampu menghasilkan prediksi untuk semua observasi di test set, termasuk yang memiliki nilai kosong. Dari sudut pandang operasional dan keandalan sistem, ini adalah keunggulan yang sangat substansial. Dengan mempertimbangkan trade-off ini, Median Imputation muncul sebagai pilihan yang paling seimbang: F1-Score tertinggi di antara metode imputasi (0,8463), waktu komputasi yang efisien (~30,9 detik), dan mempertahankan cakupan prediksi penuh pada seluruh dataset.

4.7.4 Analisis Pola Missing Secara Spasial dan Temporal

Sebagai bagian dari kontribusi tambahan penelitian ini terhadap Gap 2 yang diidentifikasi pada Bab 2, dilakukan analisis eksploratif pola missing value dari dimensi spasial (per lokasi stasiun cuaca) dan temporal (per tahun observasi). Analisis ini bertujuan untuk mengidentifikasi apakah pola kehilangan data bervariasi secara sistematis antar lokasi atau antar periode waktu, yang pada gilirannya memiliki implikasi terhadap ketepatan asumsi mekanisme MAR.

- **Dimensi Spasial**

Beberapa kota seperti Albury, BadgerysCreek, dan Ballarat memiliki tingkat missing hingga 100% untuk variabel Sunshine dan Evaporation, sementara kota seperti Brisbane dan Cairns memiliki missing rate mendekati 0% untuk variabel yang sama. Variasi ekstrem ini mengindikasikan bahwa pola kehilangan data sangat bergantung pada infrastruktur stasiun di lokasi tertentu, bukan pada kondisi cuaca semata. Ini adalah indikasi kuat adanya elemen MAR atau bahkan MNAR berbasis lokasi.

- **Dimensi Temporal**

Analisis per tahun mengungkapkan bahwa tingkat missing value variabel Sunshine meningkat secara konsisten dari 0% pada tahun 2007 hingga mendekati 74% pada tahun 2017. Tren yang meningkat seiring waktu ini adalah indikasi potensial mekanisme MNAR — di mana kemungkinan suatu nilai hilang berubah secara sistematis seiring berjalannya waktu, terlepas dari nilai variabel itu sendiri. Implikasi metodologisnya adalah bahwa strategi imputasi global (satu imputer untuk seluruh dataset) mungkin tidak optimal dan perlu digantikan dengan strategi imputasi berbasis lokasi atau berbasis periode waktu.

4.8 Ringkasan Temuan dan Rekomendasi

Berdasarkan seluruh analisis yang telah dilakukan pada subbab-subbab sebelumnya, Tabel 4.4 merangkum perbandingan komprehensif kelima strategi penanganan missing value dari berbagai dimensi yang relevan untuk pengambilan keputusan praktis.

Tabel 4.4 Matriks Perbandingan Komprehensif Kelima Strategi Imputasi

Kriteria	Baseline	Mean	Median	KNN	MICE
F1-Score	0,8530	0,8459	0,8463	0,8448	0,8459
AUC-ROC	0,8979	0,8884	0,8882	0,8847	0,8869
Kelengkapan Data	~41%	100%	100%	100%	100%
Waktu Komputasi	Cepat	Cepat	Cepat	Sangat Lambat	Sedang
Preservasi Distribusi	Tinggi	Rendah	Rendah	Sedang	Tinggi
Robust thd Outlier	Sedang	Rendah	Tinggi	Sedang	Sedang
Cakupan Prediksi Nyata	Terbatas	Penuh	Penuh	Penuh	Penuh
Rekomendasi Konteks	Data lengkap tersedia	Baseline alternatif	Produksi umum	Dgn normalisasi	Riset mendalam

Secara keseluruhan, hasil penelitian ini menegaskan bahwa tidak ada satu strategi imputasi yang secara universal superior untuk semua konteks dan tujuan. Pemilihan strategi yang tepat harus mempertimbangkan: (1) mekanisme missing value yang berlaku, (2) tujuan utama model (maksimalisasi performa vs maksimalisasi cakupan), (3) ketersediaan sumber daya komputasi, dan (4) karakteristik algoritma klasifikasi yang digunakan. Untuk konteks prediksi curah hujan operasional yang membutuhkan ketangguhan dan cakupan penuh, Median Imputation merupakan pilihan yang paling direkomendasikan sebagai keseimbangan optimal antara performa, efisiensi, dan keandalan.

5. Kesimpulan dan Saran

5.1 Kesimpulan

Penelitian ini telah berhasil melakukan komparasi sistematis terhadap lima strategi penanganan missing value pada dataset meteorologi Rain in Australia, menggunakan Random Forest Classifier sebagai model evaluasi yang seragam dalam skenario yang terbebas dari kebocoran data. Berdasarkan seluruh eksperimen dan analisis yang telah dilakukan, berikut disampaikan kesimpulan yang menjawab keempat rumusan masalah penelitian.

Rumusan Masalah 1 Karakteristik dan Mekanisme Missing Value:

Dataset Rain in Australia mengandung missing value pada 19 dari 23 kolom, dengan tingkat kehilangan yang sangat bervariasi antar variabel, mulai dari 0,87% (MaxTemp) hingga 48,01% (Sunshine) dan 43,17% (Evaporation). Analisis visual menggunakan Missingno Heatmap mengungkapkan korelasi positif yang kuat antara pola kehilangan variabel yang diukur pada waktu yang sama, seperti Cloud9am dengan Cloud3pm dan Pressure9am dengan Pressure3pm. Pola ini mengindikasikan bahwa mekanisme dominan kehilangan data pada dataset ini adalah MAR (Missing at Random), di mana kehilangan suatu nilai bergantung pada variabel lain yang terobservasi dalam hal ini, kondisi operasional stasiun cuaca. Meskipun demikian, elemen MNAR (Missing Not at Random) tidak dapat sepenuhnya dikesampingkan, terutama pada variabel Sunshine yang kemungkinan besar tidak tercatat justru pada saat kondisi cuaca paling buruk. Analisis temporal lebih lanjut memperkuat dugaan MNAR, mengingat tingkat missing Sunshine meningkat secara konsisten dari 0% pada tahun 2007 hingga mendekati 74% pada tahun 2017.

Rumusan Masalah 2 Perbandingan Performa Kelima Metode:

Secara keseluruhan, metode Baseline (Drop NA) menghasilkan performa tertinggi di semua metrik dengan F1-Score sebesar 0,8530 dan AUC-ROC sebesar 0,8979, diikuti Median Imputation (F1: 0,8463; AUC: 0,8882), Mean Imputation (F1: 0,8459; AUC: 0,8884), MICE (F1: 0,8459; AUC: 0,8869), dan KNN Imputer yang mencatat F1-Score terendah di antara semua metode (0,8448; AUC: 0,8847). Temuan ini tampak berlawanan dengan ekspektasi teoritis, namun dapat dijelaskan melalui mekanisme seleksi data implisit: observasi yang memiliki data lengkap cenderung berasal dari kondisi cuaca yang lebih teratur dan lebih mudah dimodelkan, sehingga Baseline secara tidak langsung melakukan quality filtering. Di antara keempat metode imputasi, perbedaan performa bersifat sangat marjinal (selisih $F1 < 0,002$), mengindikasikan bahwa Random Forest cukup robust terhadap perbedaan strategi imputasi dalam rentang yang diuji.

Rumusan Masalah 3 Rekomendasi Strategi Imputasi Terbaik:

Tidak terdapat satu strategi yang secara universal superior untuk semua konteks. Apabila prioritas utama adalah performa model dan data produksi memiliki kelengkapan yang tinggi, metode Baseline dapat dipertimbangkan. Namun, untuk skenario operasional dunia nyata di mana prediksi harus tetap dapat dilakukan meski sebagian sensor tidak berfungsi, Median Imputation direkomendasikan sebagai strategi yang paling seimbang: menghasilkan F1-Score

tertinggi di antara metode imputasi (0,8463) dan AUC-ROC yang kompetitif (0,8882), dengan waktu komputasi efisien (~30,9 detik), dan mempertahankan seluruh 113.754 sampel latih untuk cakupan prediksi penuh.

Rumusan Masalah 4 Pola Missing Value secara Spasial dan Temporal:

Analisis eksploratif mengungkapkan variasi spasial yang ekstrem antar stasiun cuaca. Beberapa kota seperti Albury, BadgerysCreek, dan Ballarat memiliki missing rate hingga 100% untuk variabel Sunshine dan Evaporation, sementara kota seperti Brisbane dan Cairns memiliki missing rate mendekati 0% untuk variabel yang sama. Variasi ini mengindikasikan bahwa kehilangan data sangat dipengaruhi oleh infrastruktur stasiun setempat, bukan semata-mata oleh kondisi cuaca. Dari dimensi temporal, tren peningkatan missing value Sunshine secara konsisten sepanjang 2007–2017 memperkuat dugaan adanya mekanisme MNAR berbasis waktu. Implikasi metodologis dari temuan ini adalah bahwa strategi imputasi global (satu imputer untuk seluruh dataset tanpa mempertimbangkan lokasi atau periode waktu) kemungkinan tidak optimal dan perlu digantikan dengan strategi imputasi berbasis kelompok lokasi atau berbasis periode temporal pada penelitian lanjutan.

5.2 Keterbatasan Penelitian

Penelitian ini mengakui beberapa keterbatasan yang perlu dipertimbangkan dalam menginterpretasikan hasil.

Pertama, KNN Imputer diterapkan tanpa normalisasi fitur terlebih dahulu. Fitur Pressure 9am dan Pressure 3pm yang bernilai lebih dari 1.000 berpotensi mendominasi perhitungan jarak Euclidean, sehingga tetangga yang ditemukan tidak selalu merupakan tetangga yang paling relevan secara meteorologis. Hal ini kemungkinan berkontribusi pada performa KNN yang lebih rendah dari ekspektasi teoritis.

Kedua, evaluasi performa hanya dilakukan pada satu algoritma klasifikasi, yaitu Random Forest. Hasil dan peringkat strategi imputasi belum tentu konsisten apabila diuji pada algoritma yang lebih sensitif terhadap distribusi fitur, seperti Logistic Regression atau Support Vector Machine.

Ketiga, eksperimen tidak menyertakan simulasi tingkat missing yang dikontrol secara sistematis, sehingga tidak dapat diidentifikasi pada ambang batas missing rate berapa suatu metode imputasi mulai mengungguli yang lain.

Keempat, mekanisme missing value tidak diuji secara statistik formal. Klasifikasi MCAR, MAR, dan MNAR dalam penelitian ini bersifat deskriptif dan eksploratif, bukan berdasarkan pengujian formal seperti Little's MCAR Test atau PKLM Test.

5.3 Saran

Berdasarkan temuan dan keterbatasan penelitian ini, berikut disampaikan saran untuk pengembangan lebih lanjut.

1. **Pengujian Mekanisme Missing Value Secara Formal**

Penelitian selanjutnya disarankan mengintegrasikan pengujian statistik formal terhadap mekanisme missing value, seperti Little's MCAR Test atau PKLM Test berbasis Random Forest yang dikembangkan oleh Näf et al. (2025). Pemahaman mekanisme yang lebih tepat apakah MCAR, MAR, atau MNAR akan memungkinkan pemilihan strategi imputasi yang lebih terinformasi secara statistik dan menghasilkan model yang lebih andal.

2. **Eksplorasi Imputasi Berbasis Lokasi dan Temporal.**

Mengingat variasi spasial dan temporal yang ekstrem yang teridentifikasi dalam penelitian ini, penelitian lanjutan perlu mengeksplorasi strategi imputasi berbasis kelompok lokasi (grouped imputation per kota atau per wilayah) dan berbasis periode waktu. Pendekatan hybrid yang mengintegrasikan model temporal seperti Multi-Layer Perceptron dengan teknik spasial seperti Spatial Kriging, sebagaimana diusulkan oleh Saubhagya et al. (2024), dapat menjadi arah yang menjanjikan untuk dataset cuaca dengan karakteristik spasiotemporal yang kaya.

3. **Pengujian pada Algoritma Klasifikasi yang Lebih Sensitif.**

Untuk memperoleh rekomendasi imputasi yang lebih general, penelitian berikutnya disarankan mengulangi eksperimen menggunakan algoritma yang lebih sensitif terhadap distribusi fitur, seperti Logistic Regression, Support Vector Machine, atau k-NN Classifier. Shadbahr et al. (2023) menunjukkan bahwa interaksi antara metode imputasi dan jenis classifier secara bersama-sama mempengaruhi performa secara signifikan, sehingga temuan dari satu classifier tidak dapat digeneralisasi ke classifier lain.

4. **Normalisasi Fitur Sebelum KNN Imputation.**

Pada implementasi KNN Imputer di penelitian ini, normalisasi tidak dilakukan agar kondisi preprocessing seragam antar skenario. Penelitian lanjutan disarankan membandingkan dua sub-skenario KNN: dengan dan tanpa normalisasi (StandardScaler atau MinMaxScaler sebelum KNNImputer), untuk mengisolasi dampak normalisasi terhadap kualitas imputasi dan performa downstream classification.

5. **Integrasi dengan Teknik Penanganan Class Imbalance.**

Mengingat ketidakseimbangan kelas yang cukup nyata pada dataset ini (~78% 'No' vs ~22% 'Yes'), penelitian lanjutan dapat mengeksplorasi kombinasi strategi imputasi dengan teknik oversampling seperti SMOTE (Synthetic Minority Oversampling Technique) atau ADASYN. Evaluasi apakah kombinasi tersebut dapat meningkatkan performa prediksi untuk kelas 'RainTomorrow = Yes' sangat relevan dari perspektif operasional sistem peringatan dini bencana, di mana missed detection terhadap hujan jauh lebih mahal dibandingkan false alarm.

6. **Analisis Sensitivitas terhadap Tingkat Missing.**

Penelitian lanjutan disarankan mensimulasikan tingkat missing yang bervariasi secara sistematis (misalnya 10%, 20%, 30%, 40%, 50%) pada dataset yang sama untuk mengidentifikasi ambang batas di mana suatu metode imputasi mulai mengungguli yang lain. Pendekatan ini, serupa dengan yang dilakukan Mello-Román et al. (2025), akan menghasilkan panduan praktis yang lebih spesifik mengenai kapan sebaiknya menggunakan metode imputasi tertentu berdasarkan proporsi data yang hilang.

Daftar Pustaka

- Allison, P. D. (2001). *Missing data* (Vol. 136). Sage Publications.
- Afrifa-Yamoah, E., Mueller, U. A., Taylor, S. M., & Fisher, A. (2020). Missing data imputation of high-resolution temporal climate data. *Journal of Big Data*, 7(1), 1–28. <https://doi.org/10.1186/s40537-020-00365-6>
- Aracri, F., Bizzego, A., & Esposito, G. (2025). Evaluating imputation methods for missing data in Alzheimer's neuroimaging datasets. *Scientific Reports*, 15, 8201. <https://doi.org/10.1038/s41598-025-92384-5>
- Bernal-Zubietta, J. A., Wang, Z., Vera-Candeas, P., & Rubio-Largo, A. (2025). A comprehensive review of machine learning approaches for missing data imputation in meteorological datasets. *Atmospheric Research*, 312, 107712. <https://doi.org/10.1016/j.atmosres.2025.107712>
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>
- Gabr, A. R., Abdelraouf, A. M., Nasr, G. E., & Elsaghir, H. A. (2023). Impact of missing data imputation techniques on classifier performance for healthcare datasets. *Healthcare Analytics*, 4, 100229. <https://doi.org/10.1016/j.health.2023.100229>
- García-Laencina, P. J., Sancho-Gómez, J. L., & Figueiras-Vidal, A. R. (2010). Pattern classification with missing data: A review. *Neural Computing and Applications*, 19(2), 263–282. <https://doi.org/10.1007/s00521-009-0295-6>
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.
- Jaisankar, N., Babu, E. S., & Naveen Chandra, G. (2025). Statistical methodologies for missing data analysis in machine learning: A comprehensive review. *Artificial Intelligence Review*, 58, 142. <https://doi.org/10.1007/s10462-025-10987-5>
- Jerez, J. M., Molina, I., García-Laencina, P. J., Alba, E., Ribelles, N., Martín, M., & Franco, L. (2010). Missing data imputation using statistical and machine learning methods in a real breast cancer problem. *Artificial Intelligence in Medicine*, 50(2), 105–115. <https://doi.org/10.1016/j.artmed.2010.05.002>
- Mello-Román, J. D., Hernández, A., & García-Torres, M. (2025). Sensitivity analysis of imputation methods under different missing data rates for classification problems. *Expert Systems with Applications*, 238, 122098. <https://doi.org/10.1016/j.eswa.2024.122098>

- Näf, J., Michel, L., & Meinshausen, N. (2025). PKLM: A flexible MCAR test using the classification permutation approach. *Journal of the American Statistical Association*, 120(549), 223–234. <https://doi.org/10.1080/01621459.2024.2398355>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
- Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592. <https://doi.org/10.1093/biomet/63.3.581>
- Saubhagya, R., Janith, P., & Samarawickrama, D. (2024). Hybrid spatio-temporal imputation for meteorological sensor networks using MLP and spatial kriging. *IEEE Transactions on Geoscience and Remote Sensing*, 62, 1–13. <https://doi.org/10.1109/TGRS.2024.3421873>
- Scikit-learn developers. (2023). *sklearn.impute.IterativeImputer* [Dokumentasi resmi]. <https://scikit-learn.org/stable/modules/generated/sklearn.impute.IterativeImputer.html>
- Scikit-learn developers. (2023). *sklearn.impute.KNNImputer* [Dokumentasi resmi]. <https://scikit-learn.org/stable/modules/generated/sklearn.impute.KNNImputer.html>
- Shadbahr, T., Roberts, M., Stanczuk, J., Gilbey, J., Teare, P., Dittrich, S., Ferreira, F., Kanzler, C., Reymond, M., & Schönlieb, C. B. (2023). The impact of imputation quality on machine learning classifiers for datasets with missing values. *Communications Medicine*, 3, 139. <https://doi.org/10.1038/s43856-023-00356-z>
- Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., & Altman, R. B. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics*, 17(6), 520–525. <https://doi.org/10.1093/bioinformatics/17.6.520>
- van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67. <https://doi.org/10.18637/jss.v045.i03>
- Young, W. A. (2016). *Rain in Australia* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/jsphyg/weather-dataset-rattle-package>