



Kelompok 1

Komparasi Strategi Imputasi Missing Value

Studi Kasus: Prediksi Curah Hujan Australia (*Random Forest Classifier*)

Oleh

Garis Rayya Rabbani, Refi Ikhsanti, Choirunnisa Syawaldina, Anisah Octa Rohila, Awi S. Prasetyo, Muhammad Bimastiar

01. Konteks Masalah


Krisis Missing Value pada Data Meteorologi

Kegagalan sistem transmisi telesensing dan malafungsi sensor fisik menyebabkan hilangnya entri data cuaca Australia pada skala kritis:

- **Sunshine & Evaporation:** Kehilangan data mencapai ~48%
- **Cloud9am & Cloud3pm:** Kehilangan data mencapai ~40%

Implikasi Arsitektur Model:

Standard Scikit-Learn Random Forest Classifier tidak mampu menangani data kosong secara native, mewajibkan adanya pipa pra-proses yang kokoh.



48%

Data Pelesapan

02. Ruang Lingkup Riset

Objektif & Skenario Eksperimen

Dirancang untuk mengevaluasi efektivitas penanganan data hilang lewat komparasi performa dan biaya komputasi dari 5 skenario:

01.

Baseline (Drop)

Listwise deletion dengan menghapus seluruh baris yang mengandung nilai kosong.

02.

Univariat (Mean/Median)

Substitusi nilai kosong menggunakan ringkasan statistik dari masing-masing kolom fitur.

03.

Multivariat (KNN/MICE)

Menggunakan algoritma tetangga (KNN) dan regresi linier berantai (MICE) secara iteratif.

Metodologi KDD & Protokol Zero Data Leakage




04. Eksplorasi Data Identifikasi Mekanisme Missing at Random (MAR)

Temuan Berdasarkan Analisis Korelasi:

Melalui visualisasi matriks dependensi, ditemukan korelasi hilangnya data yang sangat kuat antar waktu pengamatan.

- Hilangnya parameter cuaca sore hari (3 PM) memiliki dependensi linier terhadap tidak tercaturnya data pagi hari (9 AM).
- Kondisi ini membuktikan data bersifat Missing at Random (MAR), bukan hilang acak murni (MCAR).



05. Pemodelan Data

Karakteristik Operasional 5 Skenario Imputasi

Skenario A: Baseline (Drop Rows)

Membuang hampir 60% baris sampel.
Mengeliminasi variasi ekstrem cuaca
buruk yang merusak sensor.

Skenario D: KNN Imputer ($k=5$)

Imputasi spasial jarak Euclidean
terdekat. Memiliki beban memori
masif karena kalkulasi pasangan
baris data.

1

2

3

4

Skenario B & C: Mean & Median Imputation

Substitusi cepat univariat. Median
unggul dalam mempertahankan
kekokohan dari pencilan (outlier)
data numerik ekstrem.

Skenario E: MICE Imputation

Pemodelan multivariat terdepan.
Melakukan estimasi berantai berbasis
regresi linier untuk menjaga kovarians
antar fitur.

06. Komparasi

Performa Model



Perbedaan performa antar semua strategi imputasi sangat kecil ($\Delta < 0.002$), membuktikan ketangguhan Random Forest terhadap variasi metode pra-proses. Baseline terlihat unggul karena ia hanya menyisakan data 'bersih', hari cuaca stabil saat semua sensor berfungsi penuh, membuang hari ekstrem. Di antara metode yang mempertahankan keutuhan data, Median Imputation unggul dengan F1-Score 0.8463, mengalahkan Mean, MICE, dan KNN.

07. Implementasi & Logika Pipeline

```
# 1. Pencegahan Data Leakage
X_tr, X_ts, y_tr, y_ts = train_test_split(X, y)

# 2. Fit Imputer HANYA pada Training
imp = SimpleImputer(strategy='median')
imp.fit(X_tr)

# 3. Transform Terpisah
X_tr_imp = imp.transform(X_tr)
X_ts_imp = imp.transform(X_ts)

# 4. Training Model
rf = RandomForestClassifier().fit(X_tr_imp, y_tr)
```

Robust

Tahan terhadap outlier meteorologis ekstrem yang sering terjadi pada data cuaca

Cepat (~30 detik)

Kalkulasi ringan, efisiensi komputasi jauh lebih tinggi dibanding KNN & MICE

Reliabilitas 100%

Mencakup seluruh data produksi tanpa membuang baris seperti metode Drop

Fungsi `.fit()` hanya mengekstrak nilai median dari `X_train`, lalu `.transform()` menyuntikkan nilai tersebut ke `X_train` dan `X_test` secara terpisah. KNN butuh kompleksitas tinggi karena menghitung jarak Euclidean antar ribuan baris tanpa normalisasi skala, sedangkan Median hanya mencari nilai tengah, yang jauh lebih efisien.

08. Rekomendasi Strategis

0.8463

F1-Score (Median Imputation)

Median Imputation

Adalah pilihan paling seimbang untuk prediksi curah hujan operasional.

Next Steps: Integrasi normalisasi fitur & eksplorasi imputasi spasiotemporal (berbasis lokasi).



Terima Kasih